



# Thickener Water Recovery Sentinel

Sistema Inteligente de Detección Temprana de Crisis de Turbidez

Dataset     90 días · 5 min · 25,920 registros

Estado     Prototipo de investigación — dataset sintético



## Resumen Ejecutivo

El sistema TWS aplica modelos de Machine Learning sobre las señales de proceso del espesador para anticipar crisis de turbidez antes de que afecten la operación. El prototipo fue desarrollado y evaluado sobre un dataset sintético operacionalmente realista de 90 días.

## Resultados principales

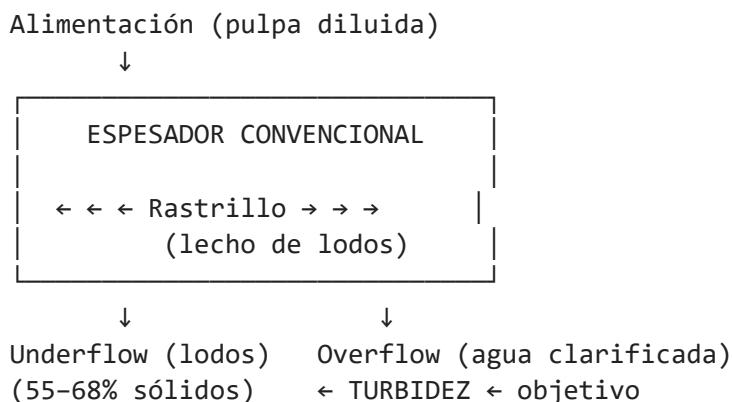
Componente	Resultado	Valor operacional
<b>Alerta Temprana 30 min</b>	Detecta el <b>79.5%</b> de las crisis con anticipación	Operador tiene ≥30 min para actuar
<b>Diagnóstico CLAY / UF</b>	Exactitud <b>93.1%</b> (regla de nivel de lecho)	Orienta la acción correctiva correcta
<b>Alerta Preventiva 2h</b>	PR-AUC <b>0.134</b> (señal débil sin datos de lab)	Define el próximo paso de madurez

**Conclusión de una línea:** TWS detecta 4 de cada 5 crisis con 30 minutos de anticipación y diagnostica correctamente la causa en más del 93% de los casos.

## 1. El Problema Operacional

## ¿Qué es un espesador y por qué importa la turbidez?

Un **espesador convencional** es el equipo central del circuito de recuperación de agua en una planta concentradora de cobre/molibdeno. Su función es separar los sólidos finos del agua de proceso, permitiendo recircular el agua clarificada al circuito de flotación.



## ¿Qué es una crisis de turbidez?

Una **crisis de turbidez** ocurre cuando el agua de overflow supera los **100 NTU de forma sostenida por 20 minutos o más**. Esto indica que partículas finas están escapando del espesador hacia el circuito de flotación.

### Consecuencias operacionales:

- Pérdida de agua de proceso recuperada (costo directo)
- Contaminación del agua de flotación → caída de recuperación de Cu/Mo
- Riesgo de impacto ambiental en caso de descarga
- Intervención manual de emergencia (ajuste de floculante, caudal de purga)

## El problema de la detección tardía

Con el sistema actual (monitoreo visual + alarmas de umbral), el operador recibe aviso **cuando la crisis ya ocurrió** ( $NTU > 100$ ). El tiempo de respuesta para aplicar la acción correctiva y ver efecto es de **15–30 minutos adicionales**.

**Objetivo de TWS:** generar alertas con **30 minutos de anticipación**, cuando el proceso todavía está en zona degradada pero aún no es crisis.

---

## 2. El Dataset

TWS fue desarrollado y evaluado sobre un **dataset sintético operacionalmente realista** de 90 días de operación continua, generado con un simulador de proceso calibrado para reproducir el comportamiento de un espesador de Cu/Mo.

## Características principales

Característica	Valor
Período simulado	90 días
Frecuencia de muestreo	5 minutos
Total de registros	25,920
Variables de proceso (tags)	30 sensores reales de planta
Variables latentes (solo simulador)	excluidas del modelo

## Distribución de zonas operacionales

Zona	Criterio (turbidez clean)	Fracción del tiempo
<span style="color: green;">●</span> Verde	< 50 NTU	<b>77.8%</b>
<span style="color: yellow;">●</span> Degradado	50 – 100 NTU	12.8%
<span style="color: red;">●</span> Crisis	> 100 NTU, ≥ 20 min	<b>5.1%</b>

## Regímenes de perturbación simulados

Se simularon dos tipos de perturbación distribuidos a lo largo del período:

Régimen	Causa	Episodios	Días totales
CLAY	Ingreso de arcilla fina al feedwell (sube Clay_idx)	3 campañas	16 días
UF	Degradación del underflow (bomba/válvula de purga)	3 campañas	12 días
NORMAL	Operación sin perturbación	—	62 días

## Fidelidad operacional del dataset

El simulador inyecta **fallas de sensor realistas** en las señales medidas:

- Spikes (picos instantáneos)
- Valores pegados (stuck values)
- Deriva gradual (drift)
- Datos faltantes (~1.5% del tiempo)

Los modelos de TWS utilizan exclusivamente la **señal medida con ruido** (como ocurriría en producción real), no los valores limpios del simulador.

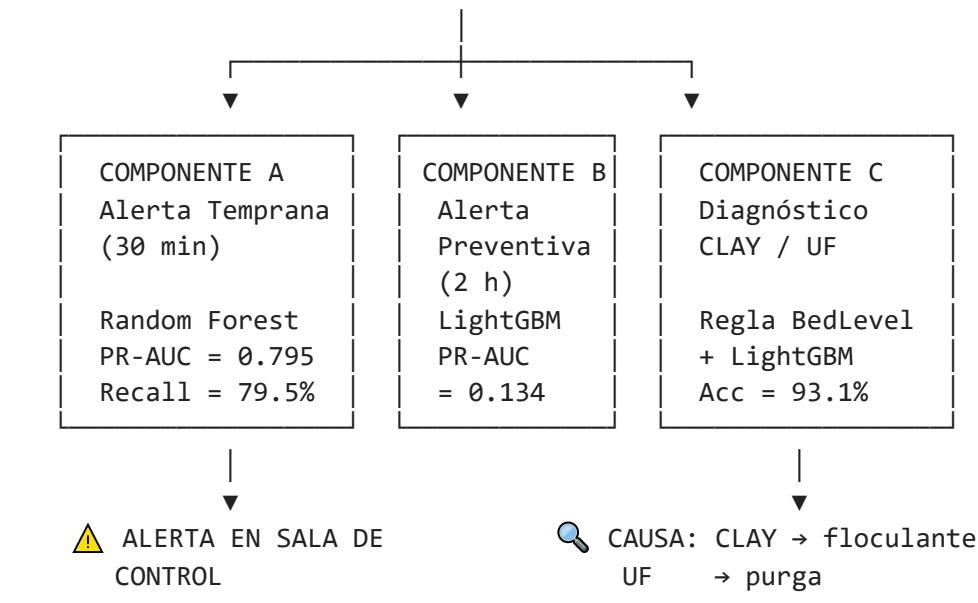
## 3. Arquitectura del Sistema TWS

TWS está compuesto por **tres componentes** que operan en paralelo sobre el flujo de datos del proceso:

---

FLUJO DE DATOS EN TIEMPO REAL  
(30 tags de proceso • frecuencia 5 min)

---



Componente	Pregunta que responde	Cuándo opera
<b>A — Alerta Temprana</b>	¿Habrá crisis en los próximos 30 min?	Siempre (continuo)
<b>B — Alerta Preventiva</b>	¿Hay riesgo de degradación en las próximas 2 h?	Solo en zona verde
<b>C — Diagnóstico</b>	¿La causa es CLAY o falla de underflow?	Cuando hay un evento

## 4. Componente A — Alerta Temprana (30 minutos)

### ¿Qué hace?

El Componente A predice, en cada instante, si el proceso entrará en crisis de turbidez (**> 100 NTU sostenido por ≥ 20 minutos**) dentro de los **próximos 30 minutos**. El modelo se ejecuta en forma continua, actualizando la predicción con cada nuevo punto de datos (cada 5 min).

### Metodología

- **Algoritmo:** Random Forest (ensemble de 200 árboles de decisión)
- **Variables de entrada:** 221 features derivadas de 30 tags de proceso (rolling statistics, lags, deltas)
- **Balance de clases:** peso automático por clase (`balanced_subsample`) — sin submuestreo artificial
- **Validación:** split temporal estricto — entrenamiento en primeros 60 días, prueba en últimos 30 días

### Resultados en datos de prueba

Métrica	Baseline (regla NTU > 80)	TWS Componente A	Mejora
Eventos detectados (Recall)	~65%	<b>79.5%</b> (416/523)	+14.5 pp
Alarmas falsas (30 días)	alta	<b>162</b>	—
PR-AUC	0.663	<b>0.795</b>	+13.2 pp
F1-macro	0.695	<b>0.870</b>	+17.5 pp
ROC-AUC	—	<b>0.986</b>	—

**Interpretación:** El modelo detecta 4 de cada 5 crisis con anticipación. Las 107 crisis no detectadas son principalmente eventos de muy corta duración o de aparición muy abrupta.

## Variables más influyentes (SHAP)

Las señales que más contribuyen a la predicción, en orden de importancia:

1. **Turbidez medida** — promedios móviles 15 min y 30 min (señal más directa)
2. **Caudal de underflow** — caída de caudal precede al colapso del lecho
3. **Nivel de lecho** — promedio de 12 h y 24 h indica acumulación progresiva
4. **Torque del rastrillo** — refleja la densidad y resistencia del lecho de lodos

## Umbral operacional

El umbral óptimo de probabilidad para emitir alarma es **P(crisis) ≥ 0.74**. Este umbral maximiza el F1-macro en datos de prueba y puede ajustarse según la tolerancia operacional al riesgo:

- Umbral más bajo → más alarmas, menos eventos perdidos
- Umbral más alto → menos alarmas falsas, mayor riesgo de no detectar

## 5. Componente B — Alerta Preventiva (2 horas)

### ¿Qué hace?

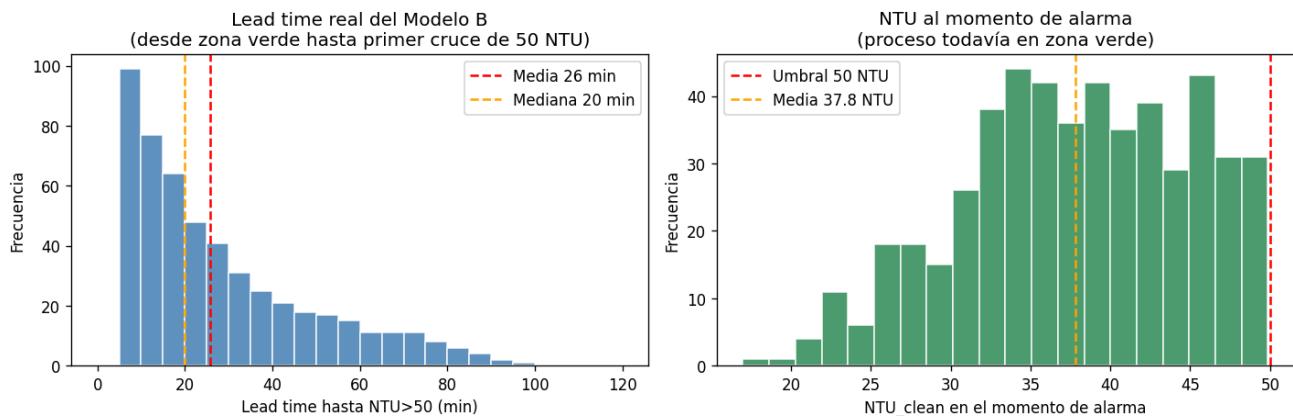
El Componente B intenta anticipar el deterioro del proceso **antes de que salga de la zona verde** ( $NTU < 50$ ). Opera solo cuando el proceso está en condición normal, con un horizonte de alerta de **2 horas**.

### Motivación operacional

El Componente A es reactivo: cuando dispara, el proceso ya está en zona degradada ( $NTU \sim 80$ ). El Componente B busca la ventana de oportunidad más temprana, cuando el operador aún tiene máxima flexibilidad de acción (ajustar floculante, reducir carga, aumentar purga de manera preventiva).

### Análisis de ventana real de anticipación

Antes de modelar, se analizó cuánto tiempo real existe desde la zona verde hasta la crisis:



### Hallazgo clave del análisis de ventana temporal:

- Tiempo promedio desde zona verde hasta zona degradada (NTU > 50): **26 minutos** (mediana: 20 min)
- El **71% de los eventos de degradación** ocurren en los primeros 30 minutos tras salir de zona verde
- El proceso en zona verde (NTU ≈ 38) **no exhibe señales claras** de la perturbación futura con 2 horas de anticipación

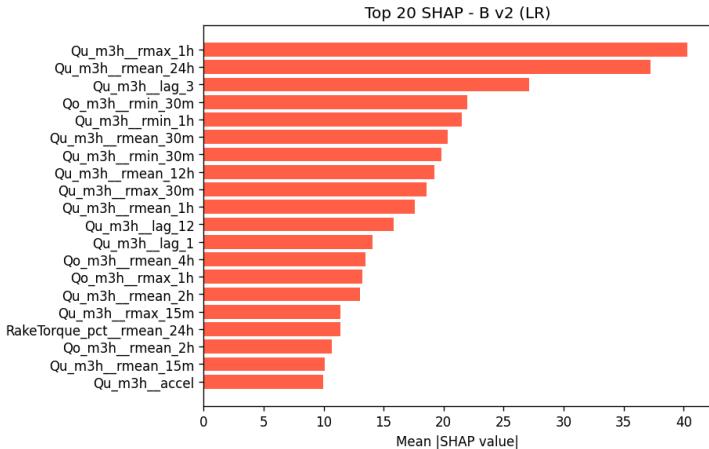
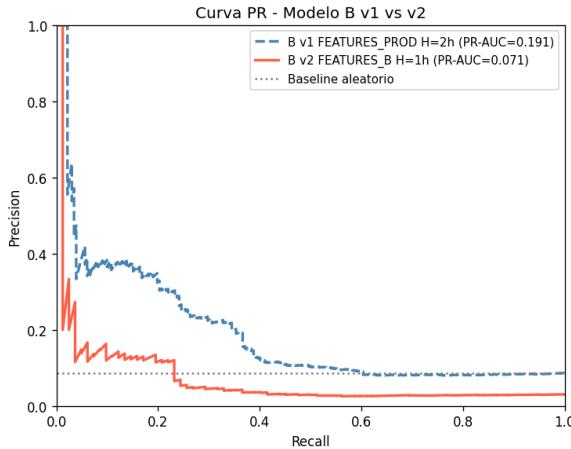
## Resultados del modelo

Se evaluaron dos configuraciones para cuantificar el impacto de distintas decisiones de diseño:

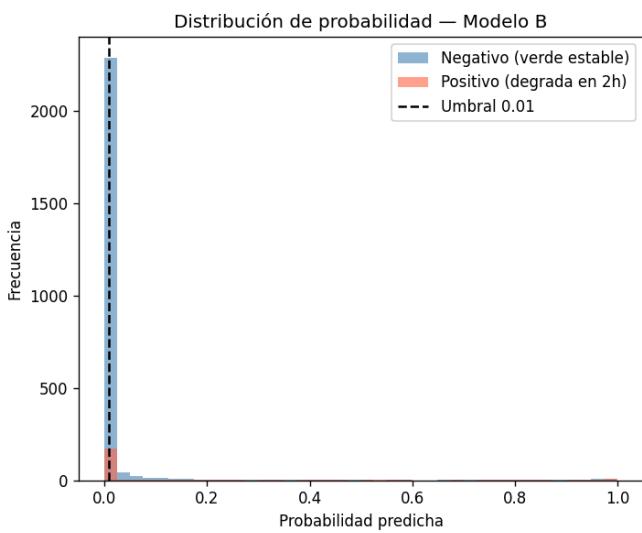
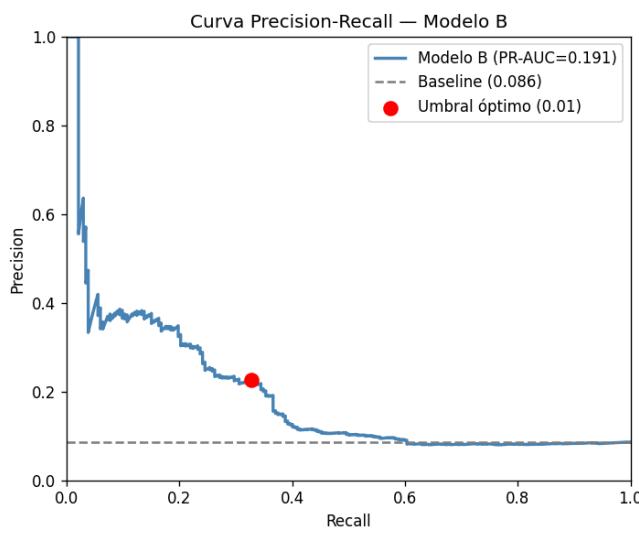
Configuración	CV PR-AUC	Test PR-AUC	Nota
v1 — con variables de régimen (leakage)	0.293	0.191	Variables no disponibles en producción
<b>v2a — sin leakage, horizonte 2h</b>	~0.28	<b>0.134</b>	<input checked="" type="checkbox"/> Configuración honesta recomendada
v2b — sin leakage, horizonte 1h	0.607	0.071	CV engañoso (sobreajuste en fold)

**Resultado honesto (v2a):** PR-AUC = 0.134, que representa un **+48% relativo** vs. el baseline de turbidez rolling.

## Análisis de la brecha CV → Test



## Curva Precisión-Recall del Componente B



## Por qué el Componente B es estructuralmente difícil

El rendimiento limitado del Componente B no es un problema de algoritmo o ajuste: es una **limitación estructural de los datos disponibles**.

**Analogía meteorológica:** predecir lluvia 2 horas antes requiere datos de presión atmosférica, humedad y sistemas frontales (variables exógenas). Con solo temperatura local, el modelo no puede anticipar el evento.

En el espesador, la señal de que viene una perturbación por arcilla (CLAY) llega primero en el **análisis granulométrico de laboratorio** (4–8 horas de delay), no en los sensores de proceso. Sin esa información, el modelo opera "a ciegas" en zona verde.

### Lo que el modelo sí aporta:

- Combina tendencias de pH, nivel de lecho y torque para detectar presiones incipientes
- Mejora en +48% relativo sobre la regla simple de turbidez rolling
- Define claramente el límite de lo que es posible con datos de sensor online

## 6. Componente C — Diagnóstico CLAY vs. UF

### ¿Qué hace?

Cuando se detecta un evento (Componente A dispara), el Componente C determina la **causa raíz** del deterioro:

- **CLAY**: ingreso de arcilla fina → lecho denso y rígido, torque elevado
- **UF (Underflow Failure)**: falla en la purga de lodos → acumulación gradual sin señal de lecho

El diagnóstico correcto es crítico porque las **acciones correctivas son opuestas**:

Causa	Acción correctiva principal
<b>CLAY</b>	Aumentar dosis de floculante · Dilución en feedwell · Reducir carga de alimentación
<b>UF</b>	Aumentar caudal de purga · Revisar bomba/válvula de underflow · Monitorear densidad
Aplicar la acción de UF a un evento CLAY (o viceversa) puede <b>agravar el evento</b> en lugar de mitigarlo.	

### Hallazgo: la regla simple supera al modelo ML

El análisis de separabilidad reveló que el **nivel de lecho** (`BedLevel_m`) es el discriminador natural entre CLAY y UF:

- **CLAY** forma una capa densa y rígida → `BedLevel_m` alto y sostenido (> 1.9 m)
- **UF** no acumula cama de lodos → `BedLevel_m` moderado (< 1.9 m)

Método	Exactitud	F1-macro	ROC-AUC
<b>Regla: <code>BedLevel &gt; 1.9 m</code> → CLAY</b>	<b>93.1%</b>	<b>0.923</b>	<b>0.922</b>
LightGBM TOP-30 features	85.4%	0.851	0.836

La **regla simple supera al modelo ML** en todos los indicadores. Esto es una buena noticia operacional: el operador puede implementar la regla de `BedLevel` sin necesidad de software adicional.

### Rol del modelo LightGBM

El LightGBM actúa como **segunda opinión** en dos situaciones específicas:

1. **Falla de sensor de nivel de lecho** (stuck, spike, datos faltantes): el modelo usa las otras 29 variables
2. **Detección temprana de tipo de evento**: el ML puede clasificar la causa antes de que `BedLevel` diverja significativamente

### Resultado operacional del diagnóstico

En el set de prueba (364 eventos de crisis):

		Predicho CLAY	Predicho UF
Real CLAY (236 eventos)	183	183 <input checked="" type="checkbox"/>	53 <input checked="" type="checkbox"/>
Real UF (128 eventos)	0	0 <input checked="" type="checkbox"/>	128 <input checked="" type="checkbox"/>

- Los 128 eventos UF se diagnostican con **100% de exactitud**
  - 53 eventos CLAY son mal clasificados como UF — todos corresponden a eventos CLAY de intensidad baja donde el nivel de lecho no llegó a superar el umbral
- 

## 7. Ventana Operacional Integrada

Los tres componentes de TWS operan en forma coordinada. El siguiente timeline ilustra cómo se comportaría el sistema durante un evento típico de tipo CLAY:

TIEMPO	TURBIDEZ	ZONA	ACCIÓN DEL SISTEMA TWS
T - 2h BedLevel al alza	38 NTU	● Verde	Comp. B: tendencia de pH y → alerta preventiva (señal débil)
T - 1h activo	42 NTU	● Verde	Comp. B: probabilidad aumenta → operador en alerta, monitoreo
T - 26m diagnóstico CLAY	50 NTU	● Degradado	Proceso cruza a zona degradada Comp. A: empieza a evaluar riesgo
T - 30m dilución	80 NTU	● Degradado	⚠️ ALERTA FIRME – Comp. A dispara → Operador tiene 30 min para actuar Comp. C: BedLevel > 1.9m → → Acción: aumentar floculante +
T 0 marcha	100 NTU	● CRISIS	Sin TWS: primer aviso recién aquí Con TWS: acción correctiva ya en
			VENTANA GANADA: ~30 minutos efectivos

### ¿Qué cambia con TWS?

Escenario	Momento del primer aviso	Tiempo para actuar
<b>Sin TWS</b> (alarma de umbral)	Cuando NTU cruza 100 (crisis ya ocurrida)	0 min de margen
<b>Con TWS Comp. A</b>	30 minutos antes de la crisis	<b>30 min de margen</b>
<b>Con TWS Comp. B</b>	Hasta 2h antes (señal débil)	<b>Hasta 2h</b> (con datos de lab)

En 30 minutos, un operador experimentado puede ajustar la dosis de floculante, ver el efecto en la turbidez medida, y realizar una segunda corrección si es necesario. El margen marca la diferencia entre una intervención proactiva y una maniobra de emergencia.

---

## 8. Limitaciones Técnicas

El prototipo TWS fue desarrollado sobre un dataset sintético. Las siguientes limitaciones deben considerarse antes de cualquier implementación en producción real:

### 1. Dataset sintético

El simulador reproduce patrones operacionales realistas, pero **no captura todos los modos de falla** posibles en una planta real:

- Perturbaciones simultáneas (CLAY + UF al mismo tiempo)
- Eventos extremos fuera del rango de calibración del simulador
- Variabilidad de mineralogía real (distintas fuentes de alimentación)

**Acción requerida:** Validar los modelos con datos históricos reales de la planta antes del despliegue.

### 2. Alerta preventiva de 2h sin datos de laboratorio

El Componente B alcanza PR-AUC = 0.134 con datos de sensor online. Este rendimiento **no es suficiente para uso operacional autónomo**. Para ser útil como sistema de alerta preventiva verdadera, requiere integración con datos de laboratorio (análisis granulométrico o asay de arcillas con delay 4–8 h).

### 3. Fallas de sensor

Los modelos fueron entrenados y evaluados con fallas de sensor inyectadas en forma realista. Sin embargo, en producción las fallas pueden ser más severas o de tipos no contemplados (corte total de comunicación, fallas de red, etc.). Se requiere una capa de validación de calidad de señal previa al modelo.

### 4. Deriva de proceso (concept drift)

Las propiedades del mineral, el desgaste de equipos y los cambios de setpoint operacional alteran el comportamiento del proceso a lo largo del tiempo. Los modelos deben ser **re-entrenados periódicamente** (recomendado: cada 3–6 meses, o ante cambios significativos de operación).

### 5. Interpretabilidad ante el operador

El Random Forest es un modelo de caja gris. Además del valor de probabilidad, el dashboard debe mostrar las **3 variables más influyentes en cada alarma** (via SHAP) para que el operador entienda por qué el sistema generó la alerta.

## 9. Próximos Pasos — Hoja de Ruta de Madurez

### MADUREZ DEL SISTEMA TWS

#### COMPLETADO — Prototipo de investigación (dataset sintético)

- Componente A: Alerta temprana 30 min (PR-AUC = 0.795)
- Componente C: Diagnóstico CLAY/UF (Acc = 93.1%)
- Componente B: Alerta preventiva (PR-AUC = 0.134, limitado)

#### PASO 1 — Validación con datos reales de planta

- Obtener historial de 6-12 meses de operación
- Re-entrenar y evaluar Comp. A y C con datos reales
- Establecer línea base de rendimiento en producción

Impacto esperado: validar o recalibrar métricas del prototipo

#### PASO 2 — Integración de datos de laboratorio

- Vincular análisis granulométrico (% arcilla, %-200 mesh)
- Re-entrenar Componente B con features de lab (delay 4-8h)
- Objetivo: PR-AUC > 0.40 en Componente B

Impacto esperado: alertas preventivas de 2h operacionalmente útiles

#### PASO 3 — Dashboard operacional en tiempo real

- Panel visual con semáforo de estado (verde/amarillo/rojo)
- Explicabilidad: top-3 variables influyentes por alarma (SHAP)
- Umbral ajustable por turno / supervisión
- Registro de alarmas y acciones (bitácora digital)

#### PASO 4 — Sistema completo + retroalimentación

- Integración con sistema DCS/SCADA de la planta
- Loop de re-entrenamiento automático (cada 3 meses)
- Registro de acciones del operador para datos de entrenamiento supervisado

## 10. Conclusiones

### Lo que funciona hoy (en dataset sintético)

1. **Alerta temprana de 30 minutos (Componente A):** El Random Forest ajustado detecta el **79.5% de las crisis de turbidez** con anticipación suficiente para que el operador actúe. Supera al baseline de umbral fijo en +17.5 pp de F1-macro.
2. **Diagnóstico de causa (Componente C):** Una **regla simple de nivel de lecho** (BedLevel > 1.9 m → CLAY) alcanza 93.1% de exactitud, lo que la hace directamente implementable en operación. El modelo ML actúa como respaldo ante fallas de sensor.

3. **Robustez a fallas de sensor:** Los modelos fueron entrenados con señales realistas que incluyen spikes, stuck values y deriva. La señal medida (no limpia) es el insumo exclusivo.

## Lo que define el próximo paso de madurez

4. **Alerta preventiva de 2h (Componente B):** Con datos de sensor online, el rendimiento es insuficiente para uso operacional autónomo (PR-AUC = 0.134). La integración de **datos de análisis de laboratorio** (% arcilla, granulometría) transformaría el Componente B en un sistema genuinamente predictivo. Este es el próximo paso crítico.

## Valor de la metodología

5. **El framework metodológico es transferible:** El pipeline de features temporales (rolling, lags, slopes), split temporal estricto, métricas correctas para clases desbalanceadas (PR-AUC), y análisis de lead time real son aplicables a cualquier proceso de espesado similar.

### Mensaje final para el equipo de planta:

TWS no reemplaza al operador — lo potencia. El sistema aporta anticipación y diagnóstico; el operador aporta contexto operacional, experiencia y decisión. La combinación de ambos es la que maximiza la recuperación de agua y la estabilidad del espesador.

## Repositorio y reproducibilidad

Artefacto	Ubicación
Simulador de datos	<code>src/simulate_fixed.py</code>
Feature engineering	<code>notebooks/02_feature_engineering.ipynb</code>
Componente A — modelado	<code>notebooks/03_modeling.ipynb</code>
Componente B — preventivo	<code>notebooks/04_model_B.ipynb</code>
Componente C — diagnóstico	<code>notebooks/04_diagnosis.ipynb</code>
Bitácora de decisiones	<code>bitacora/</code>